Restaurantes Universitários e Permanência Estudantil: análise do perfil socioeconômico e previsão de tendência ao longo do semestre

Ellen Carolina Guimarães
Instituto de Física Gleb Wataghin (IFGW) [1]
https://orcid.org/0009-0001-2569-8906
R.A.: 255137

Gabriel Ozélo Braga
Instituto de Matemática, Estatística e Computação Científica (IMECC) [1]
g247345@dac.unicamp.br
R.A.: 247345

Samuel Gomes de Lima Dias
Instituto de Matemática, Estatística e Computação Científica (IMECC) [1]
s247374@dac.unicamp.br
R.A.: 247374

Davi Jorge Negrete
Instituto de Matemática, Estatística e Computação Científica (IMECC) [1]
d239466@dac.unicamp.br
R.A.: 239466

Guilherme Valverde Freiria
Instituto de Matemática, Estatística e Computação Científica (IMECC) [1]
g270535@dac.unicamp.br
R.A.: 270535

[1] Universidade Estadual de Campinas (UNICAMP)

***Resumo*—Este artigo tem como objetivo analisar, por meio de métodos de aprendizado supervisionado e não-supervisionado de máquina, a tendência dos estudantes que frequentam os restaurantes universitários (RUs) no campus principal da Universidade Estadual de Campinas (UNICAMP) ao longo do semestre, e investigar como essa dinâmica de uso se relaciona à permanência estudantil, com ênfase em grupos socialmente minoritários.**

***Palavras-chave*—tendência dos estudantes nos RUs, permanência estudantil, aprendizado de máquina.**

***Abstract*—This article aims to analyze, through supervised and unsupervised machine learning methods, the student tendency who attends the university restaurants (RUs) on the main campus at the University of Campinas (UNICAMP) throughout the semester, and to investigate how this dynamic of use relates to student permanence, with an emphasis on socially minoritized groups.**

***Keywords*—tendency students at RUs, student permanence, machine learning.**

I. Introdução

A permanência estudantil no ensino superior brasileiro constitui um dos principais desafios enfrentados pelas universidades públicas, em um contexto marcado por desigualdades socioeconômicas que impactam diretamente a trajetória acadêmica dos discentes. Entre as políticas de assistência, os Restaurantes Universitários (RUs) ocupam posição central. Pesquisas realizadas pelo Fórum Nacional de Pró-Reitores de Assuntos Comunitários e Estudantis (FONAPRACE) indicam que o eixo Alimentação, integrante do Programa Nacional de Assistência Estudantil (PNAES), é uma das ações mais demandadas pelos estudantes das Instituições Federais de Ensino Superior [1].

Ao garantir refeições nutricionalmente adequadas e a baixo custo, os RUs contribuem para que alunos em situação de vulnerabilidade tenham melhores condições de permanecer na universidade. Mais do que assegurar a alimentação diária, esses espaços também cumprem um papel social relevante, ao promover a convivência e a integração estudantil, configurando-se como componentes estratégicos da política de permanência [2].

A evasão, entretanto, permanece como um desafio estrutural e recorrente no ensino superior brasileiro. De acordo com o Mapa do Ensino Superior, no ciclo de 2019 a 2023 a taxa de desistência acumulada nos cursos presenciais alcançou 58,4% na rede privada e 41% na rede pública, resultando em um índice geral de 54,2% de abandono [3]. Esses números evidenciam a fragilidade da permanência acadêmica, sobretudo diante de fatores como dificuldades financeiras, transporte público ineficiente, desestímulo com as disciplinas e a necessidade de conciliar trabalho e estudo, reforçando a importância de políticas de apoio, entre as quais se destacam os RUs [4].

Em sua maioria, os frequentadores dos restaurantes universitários pertencem ao grupo de estudantes de baixa renda, frequentemente vinculados a ações afirmativas de acesso, residentes em moradias estudantis ou em arranjos coletivos, e cuja renda per capita familiar é inferior a um salário-mínimo. Esses discentes realizam, em média, três refeições diárias nos RUs. Na Região Sudeste, 36,2% dos estudantes se enquadram nesse perfil, sendo os grupos mais representativos para três refeições diárias (sem recorte regional) os indígenas aldeados (54,7%), indígenas não aldeados (49,2%) e pretos quilombolas (48,1%), o que evidencia a necessidade desse serviço na garantia de condições mínimas para a continuidade acadêmica [1].

Neste trabalho, buscamos analisar o percentual de estu-

dantes em situação de vulnerabilidade que utilizam os RUs, bem como compreender as transformações na frequência de uso ao longo do semestre. Partimos da hipótese de que, embora o RU seja inicialmente frequentado por um público amplo, há uma tendência de concentração, ao longo do período letivo, entre os estudantes para os quais o serviço se torna um recurso indispensável e intermitente. Nesse sentido, o restaurante universitário funciona como um suporte essencial para a permanência no ensino superior. Para investigar essa dinâmica, desenvolvem-se métodos de aprendizado supervisionado e não supervisionado que visam não apenas compreender o padrão de uso, mas também prever a tendência de frequência dos discentes no segundo semestre de 2025.

II. Metodologia

Com o intuito de reunir informações preliminares para a pesquisa, eviou-se um e-mail à Prefeitura da Universidade Estadual de Campinas (UNICAMP) solicitando acesso a dados relativos à volumetria e aos cardápios diários dos restaurantes universitários, de acordo com a orientação da professora responsável pela disciplina, Prof.ª Petra Maria Bartmeyer, do Departamento de Matemática Aplicada.

Paralelamente, realizaram-se visitas *in loco* durante os horários de funcionamento dos restaurantes, nas quais os pesquisadores conduziram entrevistas informais com funcionários, com o objetivo de identificar os dias e cardápios de maior demanda.

Posteriormente, os dados requisitados foram obtidos por meio de protocolo junto ao Serviço de Informação ao Cidadão (SIC). A base de volumetria refere-se ao período de janeiro de 2024 à julho de 2025, intervalo adotado neste estudo [5].

Em seguida, procedeu-se à consolidação das informações em um único dataframe, visando o tratamento e a análise de forma integrada. Dentre as etapas de pré-processamento, destacou-se a normalização das opções de refeições, com o objetivo de eliminar redundâncias advindas de variações semânticas, agrupando registros equivalentes para garantir a consistência do conjunto de dados.

III. Pré-Processamento dos Dados

Após a seleção das variáveis, realizou-se o pré-processamento e a manipulação do banco de dados para adequá-lo à modelagem. Os procedimentos descritos neste artigo foram implementados utilizando a linguagem *Python*, versão 3.12.12, pelo ambiente virtual do Google Colab. Nesta seção foi utilizada a biblioteca Pandas.

Inicialmente, os cardápios foram categorizados manualmente. O cardápio tradicional seguiu as seguintes categorias: carne vermelha, sobrecoxa, strogonofes, porco, peixe, feijoada, frango (neste caso isolado, sem menção ao preparo) e outros. O cardápio vegano distribui-se da seguinte maneira: feijão branco, feijoada vegana, grão-de-bico, quibe, lentilha, PTS (proteína texturizada de soja), soja (neste caso isolada), strogonoff vegano e outros.

Em seguida, os bancos de dados de volumetria e de cardápios foram consolidados, associando cada dia de observação aos respectivos cardápios do almoço e do jantar, tanto vegano quanto tradicional. Delimitou-se o período de análise entre 29 de julho de 2024 (início do segundo semestre de 2024) e 31 de julho de 2025 (início do segundo semestre de 2025), resultando em 53 semanas, de modo a abranger observações referentes aos segundos semestres, ao primeiro semestre de 2025 e, também, ao período de atuação da nova empresa terceirizada. Cada observação foi, então, desagregada por restaurante universitário (RU, RS e RA).

Optou-se pela exclusão das observações correspondentes aos finais de semana, uma vez que apenas o RS permanece em funcionamento nesses períodos, o que poderia induzir viés à análise.

Conjunto a isso, incorporou-se ao conjunto de dados variáveis complementares como o dia da semana e a semana relativa do semestre letivo, objetivando perceber possíveis padrões sazonais associados à rotina acadêmica.

Por fim, adicinou-se a variável de precipitação pluviométrica média (em mm) durante o horário de funcionamento dos RUs, obtida através do Centro de Pesquisas Meteorológicas e Climáticas Aplicadas à Agricultura (CEPAGRI) [6], criando duas variáveis numéricas: “chuva_no_almoco” (12h-14h) e “chuva_no_jantar” (18h-20h). Tais variáveis foram normalizadas pela técnica min-max para uma escala [0,1], em que os extremos correspondem aos dias de menor e maior precipitação do dataset, respectivamente.

IV. Análise Descritiva

Nesta seção foram utilizadas as bibliotecas: Pandas, Numpy, Matplotlib e Seaborn.

Para as análises descritas a seguir determina-se o 2º semestre de 2024 como “semestre par”, já o 1º e 2º semestre de 2025, considerando o período do dia 02 de fevereiro ao dia 31 de julho, como “semestre ímpar”.

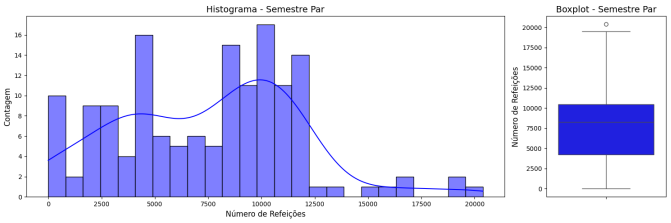


Fig. 1. Histograma e boxplot do número de refeições servidas nos RUs por dia, semestre par - Fonte: Elaboração dos autores.

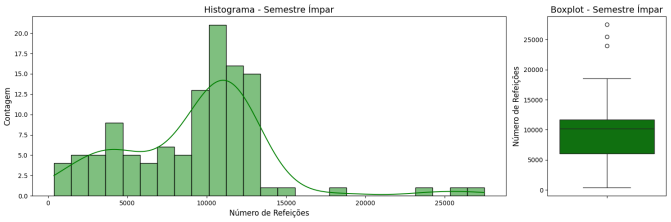


Fig. 2. Histograma e boxplot do número de refeições servidas nos RUs por dia, semestre ímpar - Fonte: Elaboração dos autores.

As análises estatísticas dos histogramas mostram que o volume médio de refeições diárias varia significativamente entre os períodos (p = 0,0015). No semestre par, registrou-se uma média de 9.297 refeições por dia (desvio padrão: 4.631,43) ao longo de 149 dias. Esse número representa um aumento de 23,9% em relação ao semestre ímpar, que teve uma média de 7.503 refeições por dia (desvio padrão: 4.287,79) em 114 dias.

A partir da análise dos boxplots, vê-se que o semestre par registrou apenas um outlier, em outubro de 2024, totalizando 20.390 refeições. Por outro lado, o semestre ímpar registrou três outliers, concentrados nos meses de março e maio de 2025. O maior deles registrou 27.496 refeições, um recorde histórico durante o período analisado.

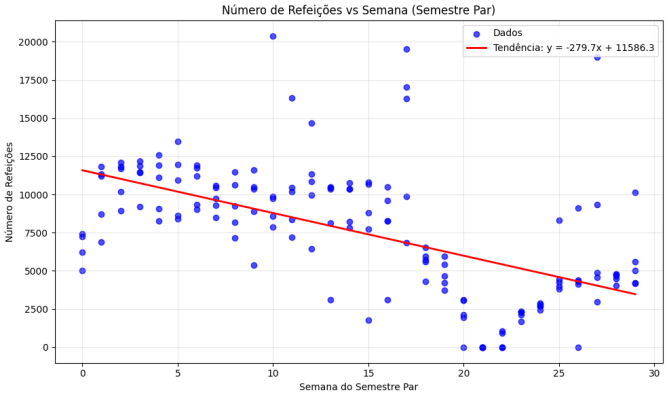


Fig. 3. Dispersão da quantidade de refeições ao longo das semanas, semestre par - Fonte: Elaboração dos autores.

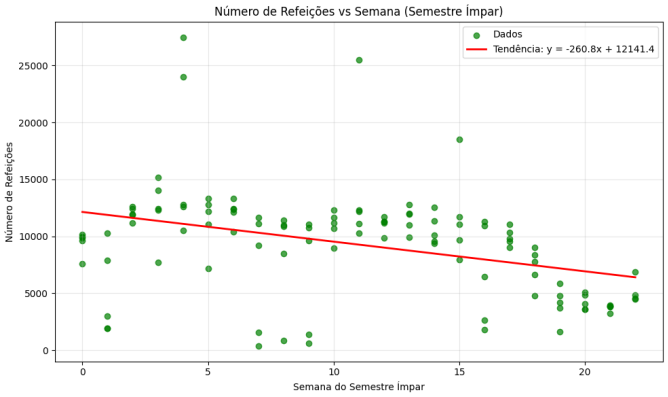


Fig. 4. Dispersão da quantidade de refeições ao longo das semanas, semestre ímpar - Fonte: Elaboração dos autores.

Os gráficos de dispersão indicam que o semestre par detêm maior variabilidade nas semanas iniciais, com tendência decrescente no volume de refeições, apresentando picos proeminentes da semana 10 à 15 e uma queda notável da semana 15 a 25. Por outro lado, o semestre ímpar apresenta menor dispersão dos dados, com volume de refeições reduzido ao final do semestre, a partir da semana 17.

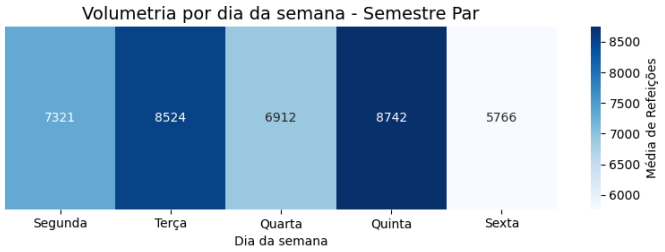


Fig. 5. Volumetria das refeições por dia da semana, semestre par - Fonte: Elaboração dos autores.

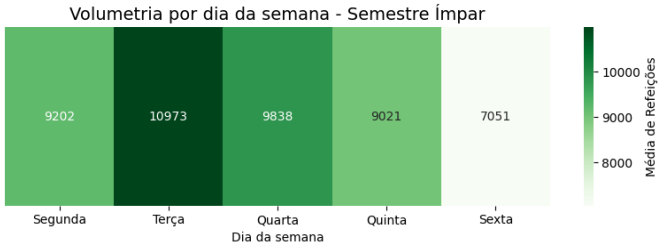


Fig. 6. Volumetria das refeições por dia da semana, semestre ímpar - Fonte: Elaboração dos autores.

De acordo com a volumetria das refeições, por dia da semana, o semestre par apresenta maior média do número de refeições servidas às terças e quintas-feiras, já o semestre ímpar apresenta, de maneira mais contundente, apenas a terça-feira, sendo este o dia com a maior média do intervalo.

Vê-se que a quarta-feira é o dia com maior crescimento percentual (+42,3%) entre os semestres. A sexta-feira mantém-se consistentemente como o dia de menor engajamento no número de refeições servidas em ambos os períodos. O crescimento geral de 23,7% na média diária para o semestre ímpar, associado à maior homogeneidade na distribuição, ou seja, menor variabilidade entre os dias da semana (14,6%, em comparação a 15,3% no semestre par), evidencia a influência direta do calendário e da rotina universitária sobre a demanda nos RUs.

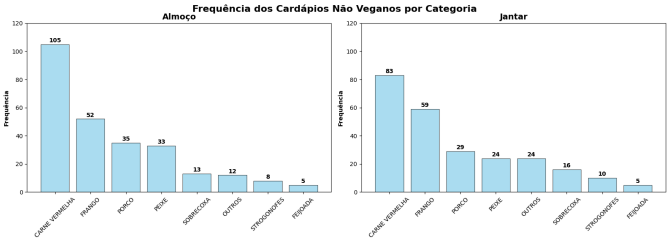


Fig. 7. Frequência dos cardápios não veganos por categoria - Fonte: Elaboração dos autores.

A frequência dos cardápios não veganos por categoria evidencia uma predominância da categoria “Carne Vermelha”, tanto no almoço quanto no jantar, com 105 e 82 ocorrências, respectivamente. Em seguida, a categoria “Frango” se destaca, com 52 ocorrências no almoço e 59 no jantar. Já categorias

como “Peixe” e “Porco” apresentam menor representatividade entre as proteínas tradicionais, variando entre 24 e 35 ocorrências.

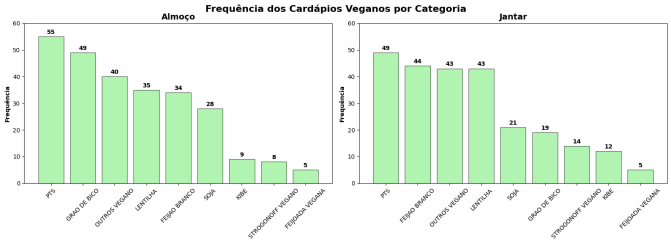


Fig. 8. Frequência dos cardápios veganos por categoria - Fonte: Elaboração dos autores

A frequência dos cardápios veganos por categoria evidencia o predomínio das preparações à base de “PTS” (proteína texturizada de soja), que se destacam como a principal fonte proteica tanto no almoço, com 69 ocorrências, quanto no jantar, com 67 ocorrências.

A categoria “Grão-de-bico” ocupa a segunda posição no almoço, com 49 ocorrências, entretanto no jantar há apenas 19 ocorrências, ocupando a sexta colocação. Já a categoria “Feijão Branco” apresenta 34 ocorrências, ocupando o quinto lugar no almoço, mas ascende à segunda colocação no jantar, com 44 ocorrências.

Note, então, que existem pratos que apresentam maior adesão no almoço em relação ao jantar e vice-versa, indicando variações no perfil dos discentes de acordo com o turno.



Fig. 9. Boxplots do número de refeições servidas por restaurante - Fonte: Elaboração dos autores.

A análise dos boxplots indica uma diferença significativa na média do número de refeições entre o Restaurante Universitário (RU) e os demais restaurantes (RA e RS). O RU apresenta uma média de 5.169 refeições diárias (desvio padrão: 1739), representando 58,4% de todas as refeições servidas, enquanto RS representa 23,6% (média: 1.982, desvio padrão: 766) e RA representa 18,1% (média: 1.638, desvio padrão: 518). Portanto, nota-se que o RU é o restaurante de maior capilaridade e demanda da UNICAMP.

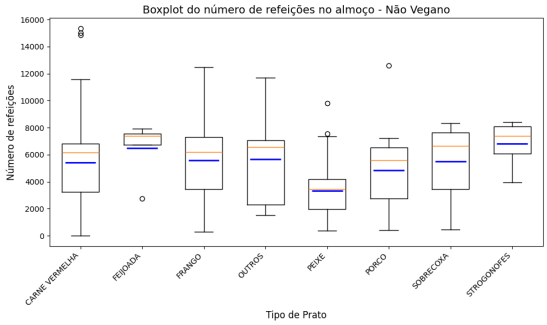


Fig. 10. Boxplot do número de refeições servidas no almoço, cardápio não vegano - Fonte: Elaboração dos autores.

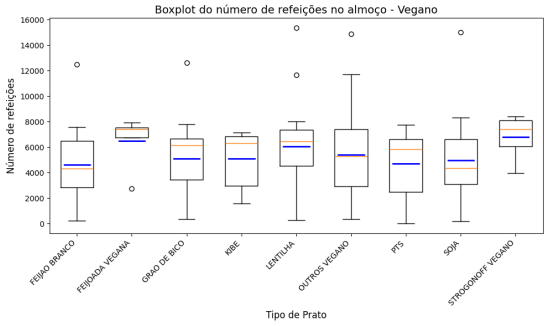


Fig. 11. Boxplot do número de refeições servidas no almoço, cardápio vegano - Fonte: Elaboração dos autores.

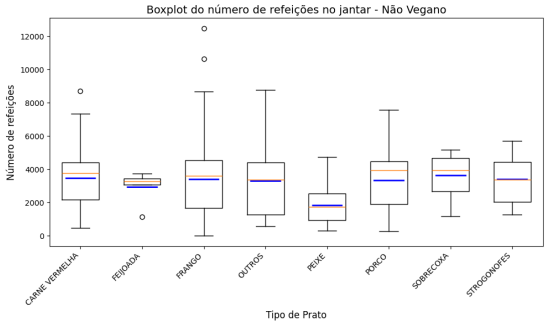


Fig. 12. Boxplot do número de refeições servidas no jantar, cardápio não vegano - Fonte: Elaboração dos autores.

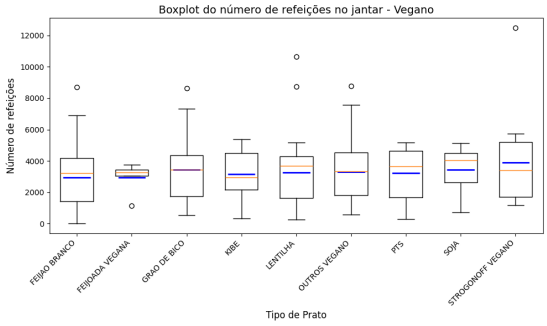


Fig. 13. Boxplot do número de refeições servidas no jantar, cardápio vegano - Fonte: Elaboração dos autores.

Conforme os boxplots do número de refeições servidas (segregadas em almoço ou jantar, cardápio não vegano ou vegano) por categorias do cardápio observa-se diferenças expressivas entre as médias, medianas e desvios padrões.

No almoço não vegano, a categoria com a maior média de refeições servidas foi "Strogonofes", apresentando 6.811 refeições (mediana: 7397.5, desvio padrão: 1.604), enquanto a menor média observada foi da categoria "Peixe", com 3.349,6 refeições (mediana: 3455, desvio padrão: 2.007). O "Peixe" apresentou o maior coeficiente de variação (= 0,599), já o "Strogonofes" demonstrou a menor variabilidade (= 0,236).

No almoço vegano, o "Strogonoff Vegano" também obteve a maior média de refeições servidas, com 6.811 refeições (mediana: 7397.5, desvio padrão: 1.604), enquanto o "Feijão Branco" apresentou a menor média, com 4.619,8 refeições (mediana: 4328.5, desvio padrão: 2.481). A categoria que apresentou maior variabilidade foi "Outros Vegano" (= 0,597), já a de menor variabilidade foi "Strogonofe Vegano" (= 0,236).

No jantar não vegano, a categoria com maior média de refeições servidas foi "Sobrecoxa", apresentando 3.636 refeições (mediana: 3952.5, desvio padrão: 1.292,3), enquanto a menor média observada foi novamente da categoria "Peixe", com 1.850,2 refeições (mediana: 1753, desvio padrão: 1.046,5). O "Frango" apresentou maior coeficiente de variação (= 0,680), já a "Feijoada" apresentou o menor coeficiente de variação (= 0,314).

No jantar vegano, a categoria "Strognoff Vegano" obteve a maior média de refeições servidas, semelhante ao almoço vegano, com 3.915,6 refeições (mediana: 3390.0, desvio padrão: 2.858,9), enquanto a "Feijoada Vegana" apresentou a menor média, com 2935.2 (mediana: 3281, desvio padrão: 922.1). A categoria que apresentou a maior variabilidade foi "Strognoff Vegano" (= 0,730), já a de menor variabilidade foi "Feijoada Vegana" (= 0.314).

Há uma preferência por parte dos discentes às categorias "Strogonofes", "Feijoada" e "Strogonofe Vegano", e, concomitantemente, uma discordância mútua com a categoria "Peixe", com a menor média tanto no almoço quanto na janta do não vegano.

V. Escolha dos modelos

A. Aprendizado Supervisionado

Para a predição do número total de refeições diárias, foram selecionados dois modelos de aprendizado de máquina supervisionado: Random Forest e Redes Neurais Multilayer Perceptron.

1) Random Forest: o algoritmo Random Forest (RF), ou Floresta Aleatória, para regressão constitui um método de *ensemble learning* que opera através da construção de múltiplas árvores de decisão durante o treinamento [7]. O mecanismo fundamental baseia-se no duplo processo de *bagging* (*bootstrap aggregating*) e na aleatorização na seleção de características. O modelo gera diversas árvores a partir de amostras *bootstrap* dos dados de treinamento e, em cada nó de divisão, considera apenas um subconjunto aleatório de variáveis preditoras, cuja cardinalidade é determinada pelo hiperparâmetro *max_features*. Este procedimento promove a diversificação entre as árvores, reduzindo o *overfitting* [8].

Cada árvore individual no *ensemble* cresce de forma recursiva através de divisões binárias, selecionando, em cada nó, a variável e o limiar de corte que minimizam o Erro Quadrado Médio (EQM). O crescimento é limitado pela profundidade máxima da árvore, controlada pelo hiperparâmetro *max_depth*. A predição final do modelo para uma nova observação é obtida pela agregação via média aritmética das predições de todas as árvores da floresta, cuja quantidade é definida pelo hiperparâmetro *n_estimators*.

Dentre as vantagens deste modelo destacam-se a robustez a outliers e a capacidade de modelar relações não-lineares e complexas entre covariáveis, sem a necessidade de especificá-las [9]. Adicionalmente, o RF oferece certo nível de interpretabilidade através das métricas, geralmente calculadas pelo decréscimo no EQM. Esta característica confere uma vantagem comparativa sobre modelos do tipo "*black-box*", como redes neurais profundas.

2) Rede Neural: o modelo de Rede Neural Multilayer Perceptron (MLP) constitui uma arquitetura de rede neural artificial *feedforward* composta por camada de entrada, camadas ocultas e camada de saída, cada uma contendo neurônios interconectados [10].

Em suma, cada neurônio realiza uma transformação não linear sobre uma combinação linear dos sinais de entrada, expressa pela equação:

$$y_j = \phi(\sum w_{ji} x_i + b_j), \tag{1}$$

onde ϕ denota a função de ativação não linear (e.g., ReLU, tanh), w_{ji} são os pesos sinápticos, e b_j é o termo de viés. Esta estrutura permite que a rede aproxime funções não lineares complexas e capture interações de alta ordem entre as variáveis preditoras [11].

O processo de aprendizagem do modelo é conduzido pelo algoritmo de *backpropagation*, que calcula o gradiente da função de perda, em nosso caso é o EQM, em relação a todos os parâmetros da rede. A otimização é realizada via algoritmos de descida de gradiente estocástica, nos quais hiperparâmetros críticos como a taxa de aprendizagem (*learning rate*) e o tamanho do lote (*batch size*) governam a estabilidade e a eficiência da convergência. A arquitetura da rede é definida pelos hiperparâmetros *hidden_layer_sizes*, que é o número de camadas ocultas e neurônios por camada, enquanto a generalização é controlada por técnicas de regularização, como penalidades L2 (*weight decay*) e *dropout* [12].

A grande vantagem do MLP é a elevada capacidade de representação, permitindo modelar dependências não lineares intrincadas e mapeamentos funcionais sofisticados quando alimentado com volumes adequados de dados e *features* com informações independentes [13]. Embora apresente maior custo computacional e menor interpretabilidade quando comparada ao RF, o MLP tende a apresentar melhor desempenho preditivo em cenários de dados complexos e de alta dimensionalidade.

Complementarmente, implementou-se um modelo de *ensemble* híbrido, em que predição final é dada pela média aritmética das saídas do RF e do MLP. Esta abordagem visa agregar as vantagens de ambos os modelos, potencialmente estabilizando as previsões e melhorando a generalização por meio da redução de variância e do viés.

B. Aprendizado Não Supervisionado

Para identificar agrupamentos (*clusters*), a fim encontrar relações entre as variáveis e as demandas do RU, bem como dias com perfis de consumo semelhantes, utilizaram-se dois modelos de clusterização de aprendizado não supervisionado: K-Means e K-Prototypes.

1) K-Means: o modelo K-Means é um método tradicional e iterativo de clusterização, conhecido por ser um algoritmo simples e de baixo custo computacional. Ele emprega a distância euclidiana entre observações como métrica de similaridade. Dado um número pré-estabelecido de clusters (K) o modelo seleciona K centróides aleatórios para a primeira iteração. Após a seleção, calcula-se a distância euclidiana entre as observações e os centróides, atribuindo cada observação à um grupo [14]. Ao término da primeira iteração, o algoritmo determina a média de cada variável para cada cluster, estabelecendo-a como o novo centróide [15]. O método continua a executar essas etapas até alcançar a convergência, ou seja, quando não há mais mudanças significativas nos centróides ou nas atribuições.

2) K-Prototypes: o modelo K-Prototypes destaca-se pela capacidade de processar variáveis categóricas. O algoritmo segue o mesmo fluxo iterativo do K-Means; entretanto, calcula a similaridade entre observações para variáveis categóricas comparando o valor com a moda do grupo: a distância é 1 se o valor for diferente da moda e 0 caso contrário [16]. A distância total, portanto, soma a distância das variáveis numéricas com a das variáveis categóricas multiplicada por um parâmetro γ (*gamma*), que regula a influência das categorias no processo de agrupamento.

VI. Aplicação dos Modelos

A. Aprendizado Supervisionado

Para o ajuste dos modelos, os dados foram particionados em conjuntos de treinamento, 80%, e teste, 20%. Nesta etapa foram utilizadas as bibliotecas: Pandas, Numpy e Scikit-learn, adotando validação cruzada *k-fold* com 5 partições para explorar o espaço de hiperparâmetros e identificar a configuração ótima.

1) Random Forest: as classes *RandomForestRegressor* e *GridSearchCV* foram utilizadas para buscar hiperparâmetros. Sendo a configuração ótima identificada: amostragem *bootstrap* = *False*, regularização *alpha* = 0.0001, *max_nodes* = 20, *max_features*="sqrt", e um *ensemble* composto por 8 árvores.

2) Rede Neural: as classes *MLPRegressor* e, novamente, *GridSearchCV* foram utilizadas para buscar hiperparâmetros. Sendo a configuração ótima identificada: função de ativação do tipo *ReLU*, arquitetura com duas camadas ocultas de 32 e 16 neurônios respectivamente, *batch learning* = 0.001, *batch size* = 64 e *alpha* = $1 \cdot 10^{-6}$.

Ambas as configurações finais, uma vez determinadas, foram reajustadas utilizando o conjunto de treinamento e, subsequentemente, avaliadas no conjunto teste.

Quanto ao modelo *ensemble*, este foi implementado como agregador simples, computando a média aritmética das predições pontuais geradas pelos modelos RF e MLP previamente ajustados.

B. Aprendizado Não Supervisionado

Nesta etapa foram utilizadas as bibliotecas: Pandas, Numpy, Scikit-learn, KMeans e KModes (função KPrototypes).

1) K-means: dada à sensibilidade do modelo às variáveis categóricas, optou-se por utilizar apenas as variáveis numéricas, são elas: "total_almoco", "total_jantar", "chuva_almoco", "chuva_janta" e "total_refeicoes".

Diferentes modelos foram testados para diferentes valores de K, variando de [2,10], a fim de encontrar a melhor configuração para a classificação. O algoritmo foi executado 10 vezes com sementes iniciais distintas, utilizando o parâmetro *n_init* = 10.

2) K-Prototypes: mantiveram-se o valor de K e os parâmetros de inicialização. Além disso, o valor de γ foi definido $\frac{\sigma}{2}$ (em que σ é o desvio padrão) das variáveis numéricas, pela função KPrototypes.

Para a escolha do número ideal de grupos, utilizamos o método do cotovelo (*Elbow Method*) em ambos os modelos. O método baseia-se no cálculo da inércia (soma dos quadrados das distâncias intra-cluster) para cada valor de K. Constrói-se uma reta entre a inércia do menor ($K = 2$) e do maior ($K = 10$) valor testado, calculando em seguida a distância da inércia de cada K à reta. O valor de K que apresenta a maior distância indica o número de grupos onde a adição de novos clusters não melhora significativamente a classificação.

Ademais, em ambos os modelos, consideramos apenas a demanda do RU, excluindo os dados do RS e RA, uma vez que incluí-los significaria segregar os clusters por restaurante, o que não condiz com o objetivo desta análise.

VII. Resultados

Nesta seção foram utilizadas as bibliotecas: Pandas, Numpy, Matplotlib e Seaborn.

A. Aprendizado Supervisionado

A performance preditiva de cada modelo foi quantificada por meio de métricas: Erro Absoluto Médio (MAE), Raiz do Erro Quadrático Médio (RMSE) e Coeficiente de Determinação (R^2). A avaliação comparativa foi realizada em um conjunto de teste comum, garantindo a comparabilidade dos resultados.

Baseando-se na análise de importância de variáveis do modelo de Floresta Aleatória, identifica-se um padrão distinto de fatores influentes na predição do volume de refeições. A variável mais significativa, após a identificação do restaurante em si, é a oferta de peixe no almoço, seguida pela quantidade de chuva, tanto no jantar quanto no almoço.

TABLE I
10 VARIÁVEIS MAIS IMPORTANTES - RANDOM FOREST

Variável	Importância
RU	0.456276
RA	0.168223
RS	0.123792
prato_almoco_normal_PEIXE	0.021391
chuva_janta	0.016996
chuva_almoco	0.011951
prato_jantar_normal_PEIXE	0.010154
prato_almoco_vegano_FEIJAO_BRANCO	0.010049
dia_semana_4	0.009827
dia_semana_2	0.008967

O peixe reaparece como fator relevante no jantar, consolidando o tipo de proteína como determinante para a demanda. Complementam o conjunto preditivo o feijão branco na opção vegana do almoço e variáveis temporais, por fim, os dias da semana correspondentes à quinta-feira e terça-feira.

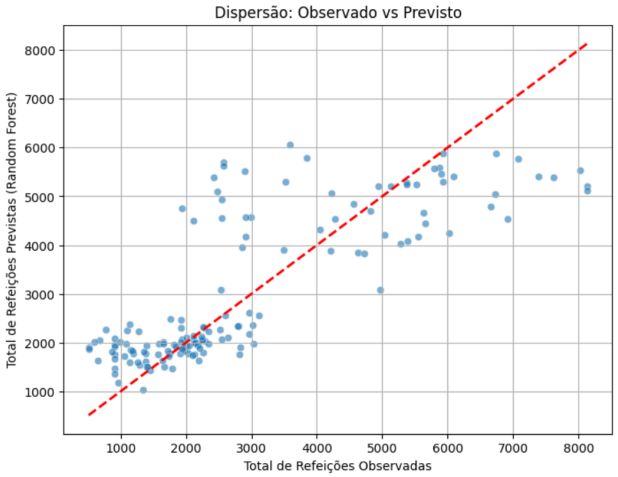


Fig. 14. Gráfico de dispersão Ajustado vs Predito para Random Forest - Fonte: Elaboração dos Autores.

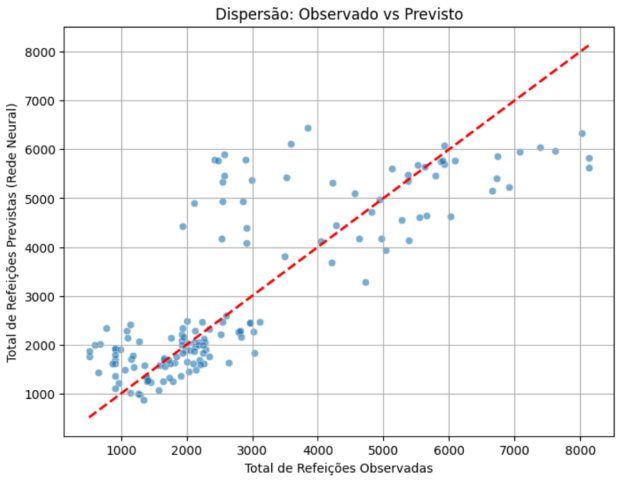


Fig. 15. Gráfico de dispersão Ajustado vs Predito para Rede Neural - Fonte: Elaboração dos Autores.

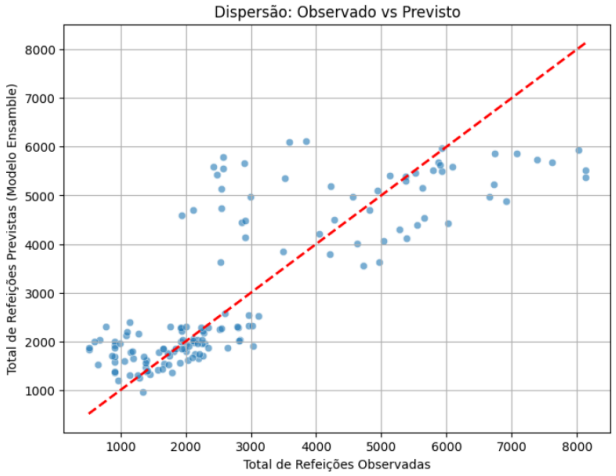


Fig. 16. Gráfico de dispersão Ajustado vs Predito para Ensamble - Fonte: Elaboração dos Autores.

A análise dos gráficos de regressão (valores previstos versus observados) revela um padrão consistente de clusterização entre os modelos testados, com concentrações distintas em torno de 2.000 e 5.000 refeições diárias. Nota-se que as previsões no cluster de menor magnitude ($\approx$ 2.000 refeições) exibem maior precisão e menor variabilidade residual, sugerindo que o modelo captura melhor os padrões acima dessa faixa de demanda.

TABLE II
MÉTRICAS DE DESEMPENHO POR MODELO

Modelo	MAE	RMSE	R^2
Ensemble	770.12	1104.07	0.654
Rede neural	775.39	1113.48	0.648
Floresta Aleatória	796.08	1123.17	0.642

Pela Tabela II, os três modelos investigados apresentam desempenho preditivo distinto, embora com diferenças marginais entre as métricas avaliadas. O modelo de Rede Neural demonstra ligeira superioridade sobre a RF, com redução de 2,6% no MAE e 0,9% no RMSE, além de incremento de 0,6 pontos percentuais no coeficiente de determinação (R^2). Esta vantagem incremental sugere que a capacidade de captura de relações não lineares das redes neurais contribui positivamente para a precisão preditiva no contexto analisado.

Notavelmente, o modelo Ensemble configura-se como a abordagem mais eficaz, registrando os menores valores de MAE (770,12) e RMSE (1104,07) e o maior R^2 (0,654). Este resultado indica que a agregação média das previsões dos modelos individuais potencializou a generalização, compensando viéses individuais e reduzindo a variância.

A superioridade do Ensemble, contudo, impõe uma ponderação crítica entre custo computacional e ganho preditivo. Considerando que o ensemble demanda o ajuste paralelo de ambos os modelos constituintes, com a complexidade da otimização de hiperparâmetros em duas arquiteturas distintas, seu custo operacional aproximadamente duplica em relação às abordagens individuais. Assim, a decisão pela implementação

do ensemble deve considerar se o incremento de 0,6% no R^2 em relação à rede neural justifica os recursos computacionais adicionais, particularmente em contextos aplicados onde eficiência operacional e escalabilidade são determinantes.

B. Aprendizado Não Supervisionado

Após ajustar o modelo K-Means, foram construídos gráficos para auxiliar na escolha do número ideal de clusters, por meio do método do cotovelo.

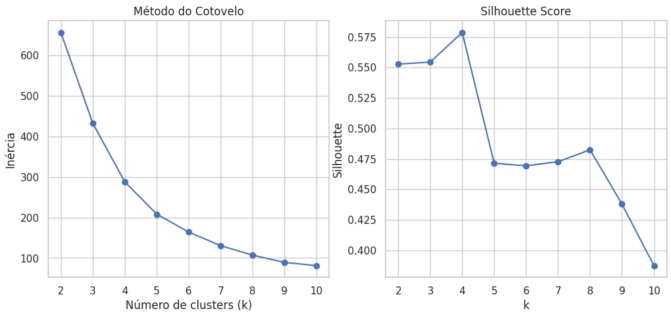


Fig. 17. Inércia e Silhouette Score para KMeans - Fonte: Elaboração dos Autores.

Observa-se que os pontos correspondentes a $k = 4, 5, 6$ se afastam da reta traçada entre as inércias de $k = 2$ e $k = 10$. Já pela análise do *Silhouette Score*, verifica-se que $k = 4$ apresenta a melhor separação entre os grupos, adotando-o ajuste do modelo KMeans.

TABLE III
CENTROIDES DE CADA CLUSTER POR VARIÁVEL E NÚMERO DE OBSERVAÇÕES - KMEANS

Grupo	total_almoco	total_jantar	chuva_almoco	chuva_janta	total_refeicoes	n de obs.
0	1.654	1.684	-0.108	-0.141	1.705	161
1	0.112	0.003	-0.003	-0.122	0.066	78
2	0.519	0.879	0.926	6.183	0.691	5
3	0.124	0.480	13.458	0.219	0.285	1

Os valores das variáveis por centroide, assim como os boxplots separados por variável e cluster, permitem analisar o perfil de cada grupo e identificar possíveis similaridades.

Inicialmente, destaca-se a distribuição das observações entre os clusters. Embora os dois primeiros grupos apresentem uma quantidade expressiva de dados (161 e 78 observações, respectivamente), os demais diferenciam-se por conter apenas 5 e 1 observações. Essas quantidades são substancialmente menores em comparação aos demais grupos.

Observa-se, principalmente, que os grupos 1 e 2 não apresentam quantidade relevante de chuva, com quase todas as observações registrando valores iguais a 0 tanto no almoço quanto no jantar. Já os grupos 2 e 3, que possuem quantidades muito menores de observações, exibem volumes elevados de chuva no jantar e no almoço, respectivamente. Assim, infere-se que esses grupos representam *outliers* associados a volumes anormais de precipitação.

Apesar do volume discrepante de chuva durante o almoço na observação pertencente ao grupo 3, a demanda permanece

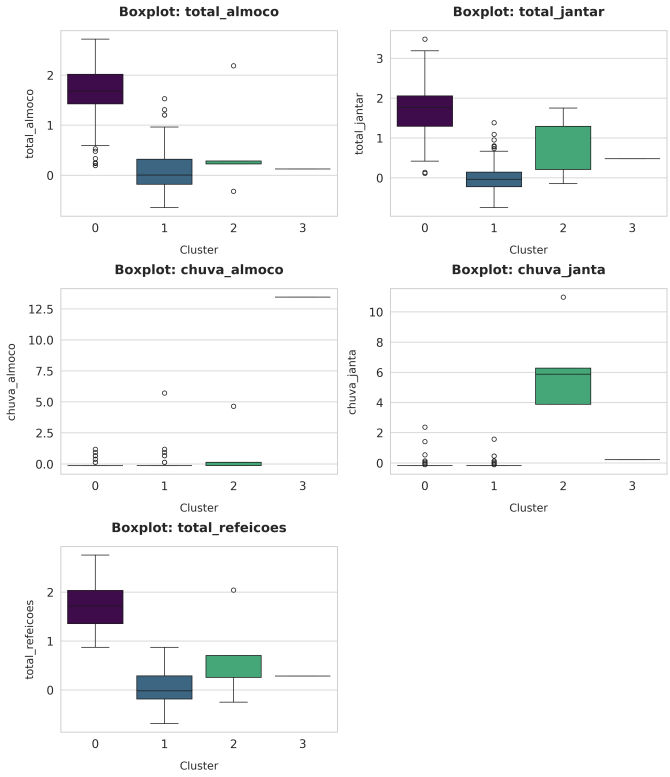


Fig. 18. Boxplot por variável e cluster para KMeans - Fonte: Elaboração dos Autores.

acima da média observada no grupo 1, que apresenta níveis irrisórios de precipitação. Uma análise semelhante é válida para o grupo 2: mesmo com maiores volumes de chuva no jantar, a demanda no período mantém-se elevada; além disso, a demanda no almoço apresenta pontos de grande dispersão, sem explicação evidente.

Acredita-se que essas inconsistências estejam relacionadas à limitação do modelo K-Means em lidar com variáveis categóricas. Isso implica que fatores como cardápio, dia da semana e semana do semestre influenciam a demanda, mas são desconsiderados pelo modelo.

Por fim, apresentam-se as principais características de cada grupo, baseadas no perfil médio e nas semelhanças entre variáveis:

- **Cluster 0 – dias de alta demanda:** caracterizado por valores elevados de total_almoco, total_jantar e total_refeicoes (centroides entre 1.65 e 1.70). Representa dias de baixa precipitação e grande movimento, típicos de semanas letivas consideradas "normais".
- **Cluster 1 – dias de baixíssima demanda:** composto por valores muito reduzidos das variáveis supracitadas (total_refeicoes $\approx$ 0.06). Representa dias de procura mínima, como feriados, recessos ou situações de funcionamento parcial.
- **Cluster 2 – demanda moderada e chuva no almoço:** apresenta demanda intermediária e níveis relativamente altos de chuva no almoço (chuva_almoco $\approx$ 0.93).

Representa dias em que a precipitação interfere na movimentação, mas sem provocar queda acentuada no consumo.

- **Cluster 3 – baixa demanda com chuva extrema:** marcado por valores extremamente elevados de chuva_almoco ($\approx$ 13.45), acompanhados de baixa demanda. Indica que chuvas muito intensas reduzem significativamente o fluxo de usuários, sobretudo no período do almoço.

Em relação ao KPrototypes, retrata-se o gráfico de inércia, em que utilizou-se o método do cotovelo para determinar o número de clusters. A métrica *Silhouette Score* não pôde, e nem deve, ser aplicada para este método, uma vez que não há compatibilidade com distâncias de variáveis categóricas.

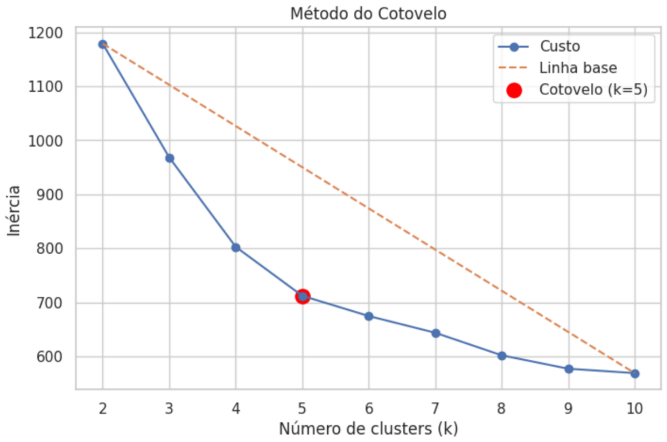


Fig. 19. Inércia para KPrototypes - Fonte: Elaboração dos Autores.

Observa-se, de acordo com o gráfico, que o valor de inércia para $k = 5$ apresentou a maior distância em relação à reta, indicando o melhor ponto para a definição do número de clusters. Ademais, obteve-se $\gamma = 0.471$, o que revela que as variáveis categóricas e numéricas receberam pesos equivalentes e aproximados, embora ligeiramente menores para as variáveis categóricas.

TABLE IV
CENTROIDES DE CADA CLUSTER POR VARIÁVEL E NÚMERO DE OBSERVAÇÕES - KPROTOTYPES

Grupo	total_almoco	total_jantar	chuva_almoco	chuva_janta	total_refeicoes	n de obs.
0	0.038226	0.101954	9.592556	0.020729	0.067481	95
1	1.205663	1.115182	-0.057772	-0.113102	1.192696	78
2	-0.020204	-0.098021	-0.106984	-0.136797	-0.055327	65
3	1.921636	2.012294	-0.125772	-0.151659	2.005594	5
4	0.519012	0.879388	0.926892	6.183150	0.691314	2

A partir da tabela e dos boxplots, é possível analisar o perfil médio de cada cluster, bem como suas semelhanças. Observa-se, inicialmente, que o número de observações em cada grupo do KPrototypes apresenta problemas semelhantes aos verificados no modelo KMeans, embora seja mais disperso devido à existência de 5 grupos. Os clusters 0, 1 e 2 possuem quantidades semelhantes de observações; entretanto, os clusters 3 e 4 concentram apenas 5 e 2 observações, respectivamente.

De maneira análoga ao modelo KMeans, nota-se que o cluster 4 se destaca por apresentar valores elevados de chuva durante o jantar, em contraste com os demais, que exibem valores extremamente baixos para essa variável. Acredita-se que o cluster 4 possua poucas observações justamente por representar registros com quantidades anormais de chuva. Observa-se também que, diferentemente do KMeans, o cluster 0 apresenta altos valores de chuva durante o almoço.

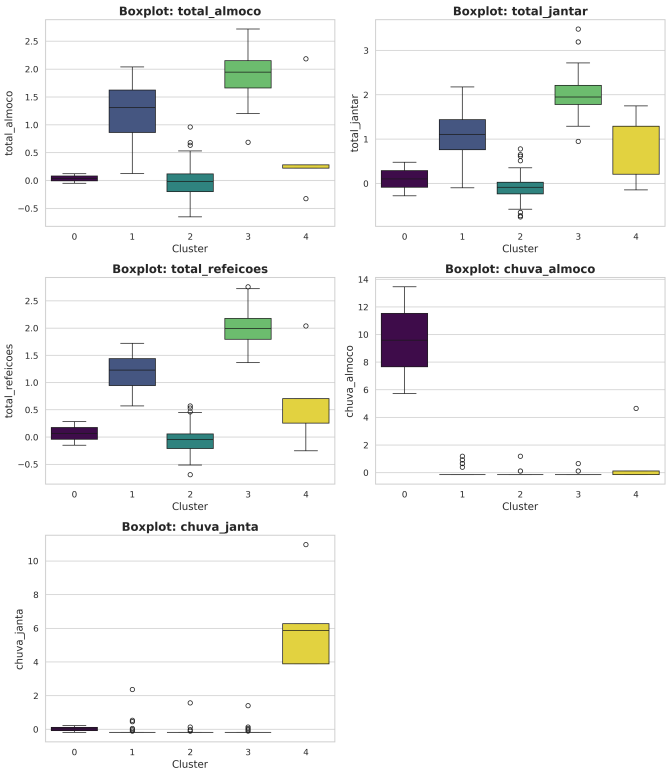


Fig. 20. Boxplots por variável e cluster para KPrototypes - Fonte: Elaboração dos Autores.

Em relação ao total de refeições, que será posteriormente comparado com a frequência de cardápios, observa-se que o cluster 3 apresenta a maior demanda, seguido pelos clusters 1 e 4. Já os clusters 0 e 2 exibem valores muito baixos de demanda. Acredita-se que o cluster 3 possua poucas observações por representar *outliers* associados a demandas atipicamente altas, possivelmente relacionadas a fatores não capturados pelas variáveis analisadas, como dias de evento na UNICAMP.

Ainda assim, torna-se relevante examinar, a partir do modelo KPrototypes, a distribuição dos cardápios entre os clusters. Os gráficos a seguir apresentam as frequências de cada variável categórica condicionadas aos respectivos grupos.

Nota-se que os clusters 3 e 4 aparecem de forma irrisória nos gráficos de barras devido à sua baixa quantidade de observações. Em razão disso, verifica-se que os cardápios exerceram pouca influência na classificação desses grupos,

dada a representatividade limitada dessas categorias nos dados.

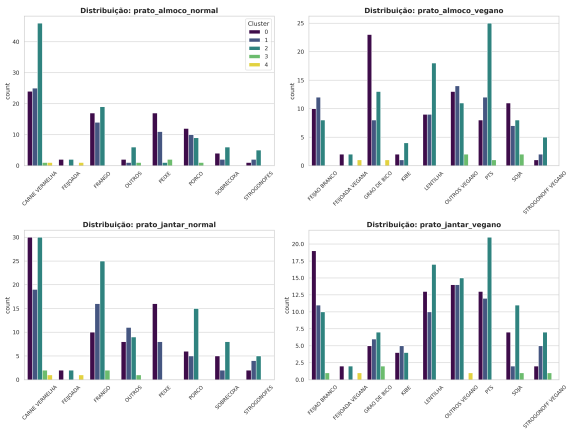


Fig. 21. Distribuição de pratos por cluster - Fonte: Elaboração dos autores.

Nos demais cardápios, observam-se diversas relações entre pratos e grupos. O grupo 0, que apresentou baixa demanda, concentrou a maior parte dos pratos de “Peixe” tanto no almoço quanto no jantar, reforçando a hipótese de que os usuários do RU tendem a evitar os dias em que esse prato é servido. Além disso, a maior parte das refeições de “Soja” e “Grão-de-bico” no almoço vegano foi classificada nesse mesmo grupo, enquanto no jantar essa concentração não se repete; nesse período, predominam no grupo 0 as refeições de “Feijão Branco” no cardápio vegano.

O grupo 1, apesar de apresentar alta demanda total (ainda inferior ao grupo 3), distribuiu-se de maneira mais uniforme entre os diferentes cardápios, incluindo contribuições notáveis do prato “Peixe”, o que contrasta com o comportamento observado no grupo 0.

Quanto ao grupo 2, que apresentou a menor demanda dentre todos os grupos, seus resultados mostram-se, de longe, os mais inesperados do método. Esse grupo destacou-se nos pratos de “Carne Vermelha” e “Frango” no cardápio regular e, de forma ainda mais marcada, nas refeições de “Lentilha” e “PTS” no cardápio vegano.

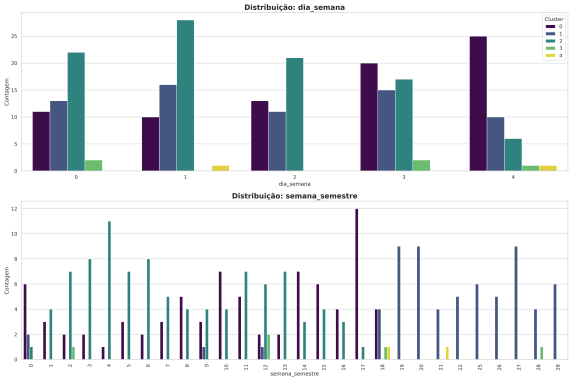


Fig. 22. Distribuição por dia da semana e por semana do semestre - Fonte: Elaboração dos autores.

A partir dos gráficos referentes ao dia da semana, observa-se que o cluster 2, caracterizado pela baixíssima demanda, concentrou a maior parte de suas observações na terça-feira, apresentando influência decrescente ao longo dos demais dias úteis. Já as observações de quinta e sexta-feira foram alocadas, majoritariamente, ao grupo 0. O grupo 1, associado à alta demanda, distribuiu-se de maneira mais dispersa entre os dias da semana, com presença particularmente reduzida na sexta-feira. Acredita-se que, nesse dia, o menor uso do RU decorra da diminuição de aulas ofertadas.

VIII. Conclusão

Este estudo realizou uma análise abrangente da demanda dos Restaurantes Universitários (RUs) da UNICAMP, investigando a dinâmica de volumetria e adesão aos cardápios no período de julho de 2024 a julho de 2025. Por meio da integração de métodos descritivos e modelos preditivos de aprendizado de máquina - supervisionado (Floresta Aleatória e Rede Neural) e não-supervisionado (K-Means e K-Prototypes) -, buscou-se caracterizar padrões de utilização e sua relação com fatores operacionais, sazonais e de preferência alimentar.

A análise descritiva revelou diferenças estatisticamente significativas tanto entre os restaurantes (RU, RA, RS) quanto entre os dias da semana, com a sexta-feira consistentemente apresentando o menor volume de refeições. A investigação da adesão aos cardápios demonstrou heterogeneidade significativa nas preferências alimentares. Preparações como strogonoff e sobrecoxa registraram as maiores médias de consumo, enquanto pratos de peixe apresentaram as menores adesões, um padrão que se mostrou crucial para os modelos preditivos.

Na análise de aprendizado supervisionado, os modelos de Floresta Aleatória (FA) e Rede Neural (MLP) foram aplicados para prever a demanda diária. A análise de importância de variáveis do modelo de FA identificou que o restaurante específico (RU, RA, RS), a oferta de peixe no cardápio e a precipitação pluviométrica foram os fatores mais influentes na predição. Um achado relevante emergiu dos gráficos de dispersão (Ajustado vs. Predito): a tendência de clusterização das previsões em dois patamares distintos (aproximadamente 2.000 e 5.000 refeições), sugerindo a existência de regimes distintos de demanda que os modelos capturaram.

Do ponto de vista preditivo, o modelo ensemble (média das previsões da FA e da MLP) apresentou o melhor desempenho no conjunto de teste, alcançando MAE = 770,12, RMSE = 1.104,07 e R^2 = 0,654, superando ligeiramente os modelos individuais. Contudo, considerando o custo computacional adicional, o modelo de Rede Neural individual (R^2 = 0,648) mostrou-se uma alternativa robusta e eficiente.

Na análise de aprendizado não-supervisionado, os modelos de clusterização (K-Means e K-Prototypes) permitiram segmentar os dias de operação em grupos com perfis de demanda semelhantes. O modelo K-Prototypes, capaz de lidar com variáveis categóricas (como o cardápio), forneceu insights mais ricos. Ele identificou, por exemplo, um cluster de baixa demanda (Cluster 0) fortemente associado a dias com cardápio de peixe e feijão branco (vegano), corroborando a análise

descritiva e supervisionada. Outros clusters capturaram perfis como dias de alta demanda (Cluster 1), dias de baixíssima demanda, possivelmente recessos (Cluster 2), e clusters com poucas observações relacionados a eventos extremos de chuva ou demanda atípica (Clusters 3 e 4). A análise da distribuição por dia da semana nos clusters reforçou o padrão de menor uso às sextas-feiras.

O papel central do Restaurante Universitário como serviço essencial para grupos socioeconomicamente vulneráveis reforça a importância de manter a oferta estável e subsidiada, particularmente em períodos críticos do calendário acadêmico. Nesse contexto, a identificação de semanas, cardápios e condições climáticas associadas a picos e quedas na demanda é fator importante para o planejamento alimentar, a logística de suprimentos e a alocação eficiente de recursos, visando ao melhor amparo dos estudantes dependentes do serviço. A capacidade de prever a demanda e entender os perfis de consumo pode auxiliar a administração dos RUs a evitar desperdícios e a garantir o acesso à alimentação adequada.

Reconhecem-se, contudo, limitações significativas na análise realizada, particularmente a exclusão dos fins de semana e a indisponibilidade de variáveis socioeconômicas individualizadas, como renda familiar ou enquadramento em políticas afirmativas, o que impede a vinculação direta dos padrões de frequência a indicadores concretos de permanência estudantil.

Recomenda-se, para pesquisas futuras, a integração sistemática entre dados operacionais dos restaurantes e indicadores socioeconômicos dos discentes, possibilitando transformar insights preditivos em políticas de assistência estudantil mais direcionadas e efetivas. A expansão do modelo para incluir mais variáveis contextuais, como o calendário de provas e eventos universitários, também poderia refinar a precisão das previsões.

Durante a preparação deste trabalho, os autores utilizaram o ChatGPT-5 e DeepSeek V3-0324 para correção e melhoria de escrita com o objetivo de otimizar o tempo. Após o uso desta ferramenta, os autores revisaram e editaram o conteúdo em conformidade com o método científico e assumem total responsabilidade pelo conteúdo da publicação.

References

[1] FONAPRACE, *"V Pesquisa Nacional de Perfil Socioeconômico e Cultural dos (as) Graduandos(as) das Instituições Federais de Ensino Superior"*, Brasília, 2018. Disponível em: https://www.andifes.org.br/wp-content/uploads/2021/07/Clique-aqui-para-acessar-o-arquivo-completo.-1.pdf.

[2] FRÓES, Ana América Gonçalves, *"Os aprendizes da casa verde: um estudo sobre a comensalidade"*, Dissertação de Mestrado, Universidade Federal da Bahia, 2010. Disponível em: https://repositorio.ufba.br/bitstream/ri/9584/1/Dissertacao%20Ana%20America%20Froes01.pdf.

[3] CORDEIRO, Mirella, *"Mapa do Ensino Superior: matrículas EAD crescem 326% em 10 anos"*, CNN Brasil, 2025. Disponível em: https://www.cnnbrasil.com.br/educacao/mapa-do-ensino-superior-matriculas-ead-crescem-326-em-10-anos/.

[4] GANAM, Eliana Almeida Soares; PINEZI, Ana Keila Mosca, *"Desafios da permanência estudantil universitária: um estudo sobre a trajetória de estudantes atendidos por programas de assistência estudantil"*, Educação em Revista, v. 37, 2021.

[5] Universidade Estadual de Campinas, *"Base de dados de volumetria e cardápios de refeições"*, Google Drive. Disponível em: https://drive.google.com/drive/folders/12lx0Jy29KwUAkoszORhfJWFkpbZZdDRm.

[6] Centro de Pesquisas Meteorológicas e Climáticas Aplicadas à Agricultura, *"Dados históricos de precipitação"*. Disponível em: https://www.cpa.unicamp.br/.

[7] Breiman, Leo, *"Random Forests"*, Machine Learning, v. 45, n. 1, pp. 5–32, 2001.

[8] Hastie, Trevor; Tibshirani, Robert; Friedman, Jerome, *"The Elements of Statistical Learning: Data Mining, Inference, and Prediction"*, 2ª edição, Springer, 2009.

[9] James, Gareth; Witten, Daniela; Hastie, Trevor; Tibshirani, Robert, *"An Introduction to Statistical Learning: with Applications in R"*, Springer, 2013.

[10] Haykin, Simon, *"Neural Networks and Learning Machines"*, 3ª edição, Pearson Education, 2009.

[11] Hornik, Kurt; Stinchcombe, Michael; White, Halbert, *"Multilayer feedforward networks are universal approximators"*, Neural Networks, v. 2, n. 5, pp. 359–366, 1989.

[12] Rumelhart, David E.; Hinton, Geoffrey E.; Williams, Ronald J., *"Learning representations by back-propagating errors"*, Nature, v. 323, pp. 533–536, 1986.

[13] Bishop, Christopher M., *"Pattern Recognition and Machine Learning"*, Springer, 2006.

[14] MacQueen, J., *"Some Methods for Classification and Analysis of Multivariate Observations"*, Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability, 1967.

[15] Tan, Pang-Ning; Steinbach, Michael; Kumar, Vipin., *"Introduction to Data Mining"*, Pearson, 2005.

[16] Huang, Z., *"Extensions to the k-means algorithm for clustering large data sets with categorical values"*, Data Mining and Knowledge Discovery, 1998.